

ARTIFICIAL INTELLIGENCE FOUNDATIONS · FUNDACIÓ URV · MAYO 2026

Predicción del Abandono Escolar con Machine Learning

Un ejemplo completo del ciclo de vida de un proyecto de ML clásico
aplicado a la retención estudiantil en educación superior.

Juli Garola e Isidro Cobo



El Problema: Un Reto Estructural Global



¿Por qué importa?

Según la OCDE, aproximadamente el **33% de los estudiantes universitarios** no completan sus estudios, generando pérdidas económicas millonarias y perpetuando desigualdades sociales.

La oportunidad

Las variables académicas, demográficas y socioeconómicas contienen **señales tempranas de riesgo** que, analizadas con ML, permiten intervenir antes de que la deserción sea irreversible.



Reto #3 · ML Clásico ·

Microcredencial AI Foundations

Formulación del Problema

Tipo de aprendizaje

Supervisado

Tarea

Clasificación binaria

Variable objetivo

Dropout / Graduate

Métrica principal

F1-Score macro ≥ 0.75


Se excluyeron los estudiantes «Enrolled» (aún en proceso). El desbalance de clases (~65% Graduate / ~35% Dropout) justifica el uso del F1-Score en lugar de la accuracy.

Los Datos: Dataset en base de datos UCI

- **4.424 registros** totales
- 36 features predictoras
- 3 clases: Dropout, Enrolled, Graduate

Dataset filtrado (proyecto)

- **2.412 registros** finales ✓
- Graduate: 1.568 (65%)
- Dropout: 844 (35%)
- Cero valores faltantes



M.V.Martins, et al. (2021) *Trends and Applications in Information Systems and Technologies*, vol.1, in *Advances in Intelligent Systems and Computing series*. DOI: 10.1007/978-3-030-72657-7_16
<https://archive.ics.uci.edu/dataset/697/predict+students+dropout+and+academic+success>

Análisis Exploratorio: ¿Qué nos dicen los datos?

Notas del 1er semestre

Correlación más fuerte con el abandono ($r = -0.52$). Las notas bajas al inicio son la señal de alerta más potente.


Nota de admisión

Los estudiantes que se gradúan presentan mediana GDA significativamente superior. ($p < 0.001$, test de Mann-Whitney).

Asignaturas aprobadas

Menos asignaturas aprobadas en el primer semestre correlacionan directamente con mayor riesgo de abandono ($r = -0.38$).

Preprocesamiento e Ingeniería de Características



El pipeline unificado de `scikit-learn` garantiza reproducibilidad: escalado estándar para variables numéricas y codificación one-hot para categóricas, con manejo de valores desconocidos.

Modelo: Random Forest Classifier

¿Por qué Random Forest?

Maneja **no-linealidades** mejor que regresión logística

Robusto a outliers frente a SVM

Proporciona **feature importance** interpretable


Entrenamiento **rápido y paralelizable**

Hiperparámetros optimizados

- **n_estimators:** 200
- **max_depth:** 20
- **min_samples_split:** 5
- **class_weight:** balanced

Tuning mediante **GridSearchCV** con validación cruzada 5-fold y scoring f1_macro.

Resultados: Evaluación en Conjunto de Test



Mejora documentada

El ajuste de hiperparámetros supuso una mejora del **+9,6%** en F1-Score macro, superando ampliamente el umbral de éxito ($\geq 0,75$).

Precisión

0,88 (Dropout)

Recall

0,74 (Dropout)

F1 Macro

0,85 ✓



Aplicación Demostrativa en Streamlit

La interfaz permite a gestores universitarios realizar **predicciones interactivas** sobre el perfil de un estudiante y visualizar el riesgo de abandono en componentes gráficos.

Entrada de datos

El usuario introduce variables académicas y demográficas del estudiante.

Output visual

El resultado se muestra en componentes visuales, no en texto crudo.

Despliegue público

App operativa en Streamlit Community Cloud para demostración en tiempo real.

<https://nfekzlqkjamzqysjnh2vro.streamlit.app/>

Conclusiones y Trabajo Futuro

✓ Lo conseguido

- F1-Score de **0,85**, superando el objetivo de 0,75
- Pipeline reproducible y modular en `scikit-learn`
- App Streamlit funcional con output parseado
- Documentación técnica completa según plantilla URV

🔭 Próximos pasos

- Integración de **datos en tiempo real** para intervención activa
- Interpretabilidad con técnicas **SHAP** por estudiante
- Validación externa en **otras instituciones**

- ✓ Este proyecto valida el ML como herramienta de apoyo a la decisión educativa institucional.